

UCUST.AI — Автономная мультиагентная SMM-экосистема

Сквозная архитектура: Парсеры • Moondream2 VLM • Сайга LLM • Умные Воронки • Realism 2.0 ComfyUI

☐

Главная ценность для бизнеса / Инвестора:

Замена целого SMM-отдела (Аналитик + Сценарист + Дизайнер + Таргетолог) на автономный 4-уровневый конвейер, который за 8 секунд собирает аналитику конкурентов, выстраивает сетку 3x3, создает конвертирующий текст по 3 ступеням воронки (TOFU/MOFU/BOFU) и рендерит фотореалистичный кадр по стандартам iPhone 16 Pro (без студийного пластика).

☐☐ Скорость генерации 6-8 сек Полный цикл с визулом	☐☐ Изоляция RAG 100% 0% утечек между клиентами	☐ Защита от бреда CriticMunger 1 мс Regex Gatekeeper	☐ Стандарт визуала Realism 2.0 26-нодовый T2I/I2I граф
---	--	---	---

1. Архитектурный каркас экосистемы (4-Tier Infrastructure)

Четкое разделение зон ответственности исключает перегрузку VRAM и гарантирует отказоустойчивость.

УРОВЕНЬ 1: Сбор и Парсинг (Ingestion) • Telethon Collector (MTPROTO): Глубокий сбор истории, комментариев и реакций. • Web Preview Scraper: Мгновенный Zero-Auth доступ к открытым каналам (t.me/s/). • VK API & 2ГИС: Сбор гео-отзывов и инфоповодов конкурентов. • Железо: 100% CPU / Async I/O (0 MB VRAM). УРОВЕНЬ 2: Мультимодальный анализ (Vision & RAG) • Moondream2 VLM: Анализ геометрии, света, контраста и извлечение Hex-палитры. • Hybrid RAG: Векторный MiniLM-L12-v2 + BM25 с изоляцией по tenant_id. • MediaUtils CV: Мгновенный фолбэк-квантизатор палитры (15 мс на CPU).	УРОВЕНЬ 3: Мозг и Арбитраж (Brain & Gatekeeper) • ContextRouter (4 квадранта): B2B_TECH, B2B_SERVICE, B2C_ECOM, B2C_LIFESTYLE. • Bridge Mode: Гармоничное скрещивание тем (IT + Котики/Кофе) без потери ДНК бренда. • Сайга LLM (Llama-3-8B): Генерация по фреймворкам BAB, PAS, AIDA, StoryBrand. • CriticMunger: 1 мс Regex Gatekeeper против B2B-оксюморонов и штампов. УРОВЕНЬ 4: Рендеринг визуала (Realism 2.0 Engine) • ComfyUI Headless (26 нод): Аппаратный свитч (Нода 72/73) между T2I и I2I. • FluxKontext Multi-Reference: Сохранение лица амбассадора и геометрии товара. • Color Guard: Инжекция 5 Hex-цветов бренда в позитивный промпт.
--	--

Ключевое преимущество для питча: Архитектура Payload-Driven переносит 80% тяжести на дешевый этап пре-роутинга (CPU), делая вызов тяжелых нейросетей точечным и безошибочным.

2. Парсеры, Moondream2 и Формула телеметрии вовлеченности

Сквозной сбор реальных данных вместо слепого угадывания интересов аудитории.

Математическая модель скоринга эффективности постов (Feedback Telemetry):
Score = (w₁ · pLike) + (w₂ · pShare) + (w₃ · pWatch) - (w₄ · pSkip)

- pShare (Репосты): Максимальный вес для органического роста охватов (TOFU).
- pLike (Одобрение): Базовый маркер согласия с ценностями и тезисами.
- pWatch (Глубина чтения): Удержание внимания на экспертных лонгридах (MOFU).
- pSkip (Штрафной вес): Фиксация пролистываний и скрытий. При росте pSkip система снижает агрессивность рекламы.

Протокол	Назначение и Глубина	Скорость	Связка с VLM Moondream2
Telethon (MTPROTO)	Полная история каналов, реакции, комментарии, закрытые группы	1.5–3 сек	Скачивание HD-оригиналов (до 2 ГБ) напрямую из Telegram DC
Web Scraper (t.me/s/)	Экспресс-аудит открытых каналов (Zero-Auth, 0 ключей, 0 риска бана)	150–300 мс	Сбор превью последних 9 постов для мгновенной сетки 3x3
VK API & 2ГИС	Сбор постов на стене, отзывов клиентов, локальных гео-трендов	200–500 мс	Анализ фотографий посетителей для выявления реальной палитры

3. Маркетинговые воронки (TOFU / MOFU / BOFU) и Авто-Арбитраж

Система автоматически балансирует ленту по правилу 50/30/20, исключая выгорание базы.

Этап воронки	Бизнес-цель	Психологический фреймворк	Правило СТА & Мемов	Стиль визуала (Realism 2.0)
TOFU (Верх воронки)	Привлечение холодного трафика, разрушение мифов, вирусные охваты	BAB (Before - After - Bridge) StoryBrand (Герой/Проводник)	☐ Мемы: РАЗРЕШЕНЫ СТА: «Перешли / Напиши мнение» ☐ Запрет жестких продаж	Живое UGC-фото на iPhone 16 Pro (24mm), естественный свет, эмоции
MOFU (Середина)	Прогрев, экспертное обоснование, демонстрация технологии, кейсы	PAS (Problem - Agitation - Solution) Архитектурные разборы	☐☐ Мемы: Ограничены СТА: «Сохрани / Задай вопрос» Умеренные метрики	Процесс работы, макро-детали интерфейса, бэкстейдж команды
BOFU (Низ воронки)	Конверсия в регистрацию, закрытие в сделку, продажа спецпредложения	AIDA (Attention-Interest-Desire-Action) FAB (Свойства-Преимущества)	☐ Мемы: СТРОГО ЗАПРЕЩЕНЫ СТА: «Купи / Оставь заявку» Четкий дедлайн и скидка	Фокус на продукте крупным планом, контрастный бренд-акцент

Детектор усталости (Audience Fatigue Lock): Если в канале вышло 2 продающих поста подряд (BOFU), система принудительно сбрасывает следующий слот в TOFU (Охват/Юмор), защищая канал от массовых отписок.

4. Единый воркфлоу генерации Realism 2.0 (ComfyUI Headless)

26-нодовый граф объединяет Text-to-Image и Multi-Reference Image Editing без переключения файлов.

Аппаратный переключатель (Ноды 72 & 73):

- Node 72 (PrimitiveBoolean Mode: Edit): Автоматически выставляет False (генерация с нуля из шума) или True (редактирование по референсам).
- Node 73 (Latent Input Switch): Направляет в KSampler либо пустой латент (Node 74), либо закодированные референсы (Node 58).

Сохранение Бренда (Multi-Reference):

- Nodes 55, 64, 65 (LoadImage): Слоты под Фото 1 (Товар/Лицо), Фото 2 (Локация), Фото 3 (Стиль).
- Nodes 62, 63 (FluxKontext): 100% консистентность физических черт продукта при смене фона.

Формула мобильного реализма (UGC Standard):

- Оптика: shot on iPhone 16 Pro, 24mm main camera, eye-level handheld.
- Освещение: natural ambient window daylight, realistic room shadows.
- Color Guard: Авто-инжекция 5 Hex-цветов из брендбука.

Жесткие негативные фильтры (Anti-Plastic):

staged studio photoshoot, heavy artificial studio strobes, plastic skin, airbrushed, wax figure, 3d render, cgi, cartoon, overly smooth, fake lighting

Матрица композиционного ритма 3x3 (Grid DNA Planning Matrix):

#1 Эмоции/Люди Человек в естеств. свете	#2 Макро-Деталь Фокус на товаре/текстуре	#3 Пространство Локация, интерьер, город
#4 Действие Динамичный процесс работы	#5 Главный Акцент Контрастный оффер / УТП	#6 Детали/Артефакты Инструменты, материалы
#7 Закулисье Бэкстейдж подготовки	#8 Соц. Пруф Результат «До/После»	#9 Воздух/Минимализм Эстетическая разгрузка

5. Аппаратная экономика и работа при высоком наплыве (High-Load)

Как система обслуживает сотни клиентов на ограниченном пуле GPU без падений по OOM.

Компонент	Устройство	Потребление памяти	Роль и Приоритет
Парсеры (Telethon, VK, 2ГИС)	☐☐ CPU (Многопоточность)	50–100 МБ RAM (0 МБ VRAM)	Фоновый приоритет (Below Normal). Сетевой асинхронный I/O
RAG Поиск (MiniLM + BM25)	☐☐ CPU (384-dim энкодер)	~150 МБ RAM (0 МБ VRAM)	Нормальный. Поиск чанков за 10–20 мс без загрузки в видеокарту
ContextRouter & CriticMunger	☐☐ CPU (Regex / Heuristics)	< 20 МБ RAM (0 МБ VRAM)	Мгновенный (1 мс). Отсечение B2B-оксюморонов до вызова нейросетей
Сайга LLM (Saiga NeMo 12B BF16)	☐ GPU (CUDA BF16 VRAM)	22.8 ГБ VRAM (на A100 / 48GB)	Высокий. Генерация авторского текста без компромиссов в слоге (35–50 токенов/сек)
ComfyUI (Qwen-Image BF16 + Realism 2.0)	☐ GPU (Tensor Cores BF16)	38.1 ГБ VRAM (DiT + VAE + LoRA)	Максимальный. Рендеринг 4-step Lightning фотореалистичного кадра за 3–5 сек
Moondream2 VLM (Зрение)	☐ GPU / CPU Fallback	3.5 ГБ VRAM / RAM Fallback	При наплыве очереди автоматически уступает VRAM под ComfyUI

Enterprise & High-Load балансировка: В Enterprise-конфигурации (Tesla A100 80GB / RTX 48GB) система использует неквантованные модели saiga_nemo_12b.BF16.gguf (22.8 ГБ) и qwen-image-2512-BF16.gguf (38.1 ГБ), которые полностью помещаются в HBM2e память. На серверах с 24–48 ГБ VRAM интеллектуальный шедулер использует Time-Division Multiplexing: Сайга генерирует текст за 1.5 сек $\rightarrow$ память очищается $\rightarrow$ ComfyUI рендерит фото за 3 сек, гарантируя нулевые задержки при пиковом наплыве.

6. Шпаргалка для питча и ответы на сложные вопросы (Pitch Cheat-Sheet)

Готовые тезисы для демонстрации инвесторам, B2B-клиентам и блогерам.

Вопрос / Возражение	Убийственный ответ и Архитектурный пруф (Killer Argument)
«Чем вы лучше ChatGPT / Midjourney?»	Обычные нейросети генерируют контент «в вакууме» без памяти. UCust — это замкнутый конвейер с обратной связью: парсер собирает реакции, Moondream считывает цвета, а Сайга адаптирует следующий пост под дефицит сетки 3x3.
«А если ИИ начнет галлюцинировать и нести бред?»	Защита встроена на уровне пре-фильтра CriticMunger. Он за 1 мс отсекает любые оксюмороны (например, попытки продать «KPI эспresso» или B2B-термины в зоо-теме).
«Почему у вас нет чата на фронтенде?»	Потому что чат — это медленно. В UCust клиент тратит 30 секунд в день в режиме Action Cards: видит готовый контент-план и подтверждает/меняет его в 1 клик.
«Как вы не смешиваете данные разных компаний?»	Вся база знаний RAG жестко изолирована по Multi-Tenant Partitioning (tenant_id). Перекрестная утечка между базой стоматологии и IT-компании математически равна 0%.
«Почему картинки не выглядят как дешевый AI-пластик?»	Мы используем 26-нодовый воркфлоу Realism 2.0 с оптикой iPhone 16 Pro (24mm, natural ambient light) и тяжелыми негативными стоп-фильтрами против студийного 3D-глянца.

ИТОГОВЫЙ СЛОГАН ДЛЯ ПИТЧА: «UCust.AI — это автономный контент-завод, где маркетинг управляется математикой, а не случайным вдохновением копирайтера».